Proposal

Đề tài: Model VLM end-to-end for Document OCR and Layout Analysis

Giảng viên hướng dẫn: PGS.TS Nguyễn Thị Kim Anh

Thông tin học viên:

Bùi Minh Đức – 20242056M

Học phần: Đồ án đề xuất

Hà Nội, ngày Ngày 11 tháng 2 năm 2026

Mục lục

1 Tóm tắt **5**

2 Giới thiệu **5**

2.1 Tổng quan về Vision Language Model 5

2.2 Các mô hình VLM và OCR thế hệ mới (OCR-2.0) 6

2.2.1 General OCR Theory and the GOT Model - GOT-OCR2.0 6

2.2.2 Qwen2.5-VL mô hình hỗ trợ Native Dynamic Resolution 8

2.2.3 Olm-OCR2.0 Architecture 10

2.2.4 MinerU2.5: Mô hình tách biệt (Decoupled Architecture) 11

2.2.5 DeepSeek-OCR 2.0: Mô hình Mã hóa Luồng Nhân Quả Thị Giác (Visual Causal Flow Encoding) 14

2.2.6 LightOn-OCR 2.0: Mô hình Ngôn ngữ-Thị giác End-to-End Nhẹ và Hiệu quả (Lightweight End-to-End VLM) 16

3 Đề xuất kiến trúc mô hình **20**

3.1 Tổng quan kiến trúc 21

3.2 Các thành phần kiến trúc 21

3.2.1 Shared Multi-Scale Encoder 21

3.2.2 Vocabulary Pruning Module 22

3.2.3 Layout Decoder 22

3.2.4 RoIAlign Module 23

3.2.5 Parallel Content Decoder 23

3.3 Training Pipeline 24

4 Dataset Engine **25**

4.1 Tổng quan Pipeline 25

4.2 Giai đoạn 1: Data Curation và Collection 25

4.2.1 Nguồn dữ liệu 25

4.2.2 Tiêu chí lựa chọn và cân bằng 26
4.2.3 Công cụ xử lý 26
4.3 Giai đoạn 2: Automated Annotation Pipeline 26
4.3.1 Ensemble Model Strategy 26
4.3.2 Model Selection cho Ensemble 27
4.3.3 Quy trình Annotation Tự động 27
4.3.4 Công cụ và Infrastructure 28
4.4 Giai đoạn 3: Human-in-the-Loop Refinement 28
4.4.1 Workflow Human Review 28
4.4.2 Priority Queue và Sample Selection 28
4.4.3 AI-Assisted Annotation Tool 28
4.4.4 Quality Control Framework 29
4.4.5 Annotator Training và Calibration 29
4.5 Đánh giá Phương pháp Ensemble + Human-in-the-Loop 29
4.5.1 Ưu điểm của Phương pháp Đề xuất 29
4.5.2 Tính khả thi và Hiệu quả kinh tế 29
4.5.3 Các chỉ số đánh giá chính 30

5 Dataset Strategy và Training Timeline 30
5.1 Phân phối Dataset theo Giai đoạn Training 30
5.1.1 Tổng quan Phân phối Dataset 30
5.2 Phase 1: Encoder Pretraining Dataset 30
5.2.1 Mục tiêu và Yêu cầu 30
5.2.2 Thành phần Dataset 31
5.2.3 Data Preparation Pipeline 31
5.2.4 Công cụ đề xuất 31
5.3 Phase 2: Layout Decoder Training Dataset 32
5.3.1 Mục tiêu và Yêu cầu 32
5.3.2 Thành phần Dataset 32

5.3.3 Annotation Specifications 32
5.3.4 Quality Control Measures 32
5.4 Phase 3: Content Decoder Training Dataset 33
5.4.1 Phân chia theo Task 33
5.4.2 Text Recognition Dataset 33
5.4.3 Table Recognition Dataset 33
5.4.4 Formula Recognition Dataset 34
5.5 Phase 4: Joint Fine-tuning Dataset 34
5.5.1 High-Quality Curation 34
5.5.2 Domain Distribution 34
5.5.3 Hard Case Mining 35

1 Tóm tắt

Phân tích và hiểu tài liệu là một trong những task vụ quan trọng trong việc khai thác và xử lý các loại tài liệu đa dạng, phức tạp, có cấu trúc. Tuy nhiên các phương pháp OCR truyền thống (OCR-1.0) hiện nay chủ yếu dựa trên Pipeline, sử dụng thiết kế dạng mô-đun, chia nhỏ nhiệm vụ thành các giai đoạn riêng biệt như phát hiện bố cục, dự đoán thứ tự đọc, và nhận dạng từng phần tử (từ, bảng biểu, công thức) và mỗi giai đoạn được xử lý bởi một mô hình chuyên biệt tuy mang lại khả năng giải thích rõ ràng (interpretability) nhưng quy trình phức tạp và dễ xảy ra lan truyền lỗi (error propagation) giữa các mô-đun. Để giải quyết những hạn chế này, các nghiên cứu gần đây giới thiệu các mô hình OCR-2.0 thông qua việc áp dụng các mô hình Ngôn ngữ - Thị giác lớn (LVLMs) tiên tiến như: DeepSeek-OCR, GOT, MinerU2.5, Qwen2.5-VL,...

Dựa vào các kiến trúc có khả năng phân tích và hiểu tài liệu một cách toàn diện (omni-parsing), tôi đề xuất mô hình VLM end-to-end có khả năng phân tích tài liệu phức tạp, có thể ứng dung cho tài liệu Tiếng Việt, đặc biệt hướng đến phương pháp nén ảnh compression encoder để giảm số lượng vision token, cộng với áp dụng Prunning Vocabulary để giảm số lượng tokens mã hóa cho khối decoder nhằm tăng tốc độ sinh token cho bài toán autogressive, đồng thời đề xuất một vài công cụ sử dụng cho việc tạo và sinh dataset thay vì thủ công.

2 Giới thiệu

2.1 Tổng quan về Vision Language Model

Mô hình Ngôn ngữ - Thị giác lớn (LVLMs) là sự mở rộng của các mô hình ngôn ngữ lớn (LLMs) truyền thống, cho phép tiếp nhận và xử lý dữ liệu hình ảnh bên cạnh văn bản. Sự tích hợp này giúp AI mô phỏng tốt hơn khả năng nhận thức của con người, không chỉ dừng lại ở việc mô tả hình ảnh hay trả lời câu hỏi (VQA) mà còn mở rộng sang các tác vụ phức tạp như xác định đối tượng (grounding), tạo văn bản (OCR), và vận hành thiết bị.

Trong giai đoạn gần đây, các nghiên cứu đang chuyển từ các quy trình phân đoạn (pipeline) truyền thống sang các mô hình đầu cuối (end-to-end), đặc biệt trong lĩnh vực xử lý tài liệu và OCR (được gọi là CR-2.0).

Hầu hết các LVLM hiện đại đều tuân theo mô hình kiến trúc:

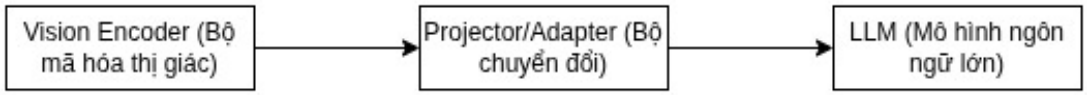

Hình 1: **VLM Pipeline**

Bộ mã hóa thị giác (Vision Encoder):

- Nhiều mô hình sử dụng các bộ mã hóa dựa trên Transformer (ViT) được khởi tạo từ CLIP hoặc các biến thể của nó để trích xuất đặc trưng hình ảnh.

- Tuy nhiên, các nghiên cứu mới như Qwen2-VL và MinerU2.5 đã chuyển sang sử dụng bộ mã hóa độ phân giải gốc (native-resolution) hoặc hỗ trợ độ phân giải động (dynamic resolution) để xử lý hình ảnh ở nhiều tỷ lệ khác nhau mà không làm mất chi tiết.

- DeepSeek-OCR sử dụng kiến trúc "DeepEncoder"kết hợp SAM và CLIP để nén thông tin thị giác.

Cơ chế kết nối (Adapter/Projector):

- Thành phần này nén hoặc chuyển đổi đặc trưng hình ảnh để phù hợp với không gian vector của LLM. Ví dụ, Qwen-VL sử dụng một bộ chuyển đổi nhận biết vị trí (Position-aware Vision-Language Adapter) để nén đặc trưng ảnh thành chuỗi cố định.

- LightOnOCR sử dụng MLP hai lớp kết hợp với việc gộp không gian (spatial merging) để giảm số lượng token.

Mô hình ngôn ngữ (LLM Decoder):

- Đóng vai trò là xử lý suy luận và sinh văn bản. Các mô hình phổ biến như Qwen, Vicuna, hoặc LLaMA thường được sử dụng làm nền tảng.

2.2 Các mô hình VLM và OCR thế hệ mới (OCR-2.0)

2.2.1 General OCR Theory and the GOT Model - GOT-OCR2.0

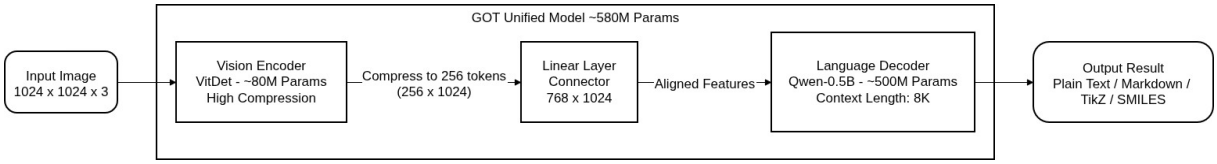

Hình 2: **GOT-OCR2.0-Architecture**

(a) **Tổng quan kiến trúc (Architectural Overview)**

GOT-OCR2.0 là một mô hình OCR End-to-End thống nhất, được thiết kế theo kiến trúc Encoder–Decoder đơn giản và gọn nhẹ. Tổng số tham số của mô hình vào khoảng 580M.

(b) **Bộ mã hóa hình ảnh (Vision Encoder)**

Bộ mã hóa hình ảnh sử dụng kiến trúc ViTDet (phiên bản base) với khoảng 80M tham số.

Điểm nổi bật của Vision Encoder trong GOT là khả năng nén mạnh (high-compression rate): thay vì tạo ra hàng nghìn token như các mô hình OCR sử dụng cơ chế cửa sổ trượt, encoder của GOT nén một ảnh đầu vào kích thước 1024×1024 pixel thành chỉ 256 token, với kích thước đặc trưng 256×1024. Thiết kế này giúp giảm đáng kể chi phí tính toán và bộ nhớ trong giai đoạn suy luận.

(c) **Lớp tuyến tính(Linear Layer)**

Một lớp tuyến tính được sử dụng như một cầu nối (connector) giữa bộ mã hóa hình ảnh và bộ giải mã ngôn ngữ. Lớp này có nhiệm vụ ánh xạ không gian đặc trưng từ kích thước 256×1024 (đầu ra của encoder) sang 768×1024, nhằm đảm bảo sự tương thích với kênh đầu vào của bộ giải mã.

(d) **Bộ giải mã ngôn ngữ (Language Decoder)**

Bộ giải mã ngôn ngữ sử dụng mô hình Qwen-0.5B với khoảng 500M tham số. Decoder tiếp nhận các đặc trưng hình ảnh đã được căn chỉnh và sinh ra chuỗi văn bản đầu ra tương ứng. Một ưu điểm quan trọng của mô hình ngôn ngữ này là khả năng hỗ trợ độ dài ngữ cảnh lên đến 8000 token, cho phép GOT xử lý hiệu quả các trang tài liệu dày đặc văn bản, các tác vụ OCR đa trang (multi-page), cũng như các định dạng phức tạp như bản nhạc hoặc biểu đồ.

2.2.2 Qwen2.5-VL mô hình hỗ trợ Native Dynamic Resolution

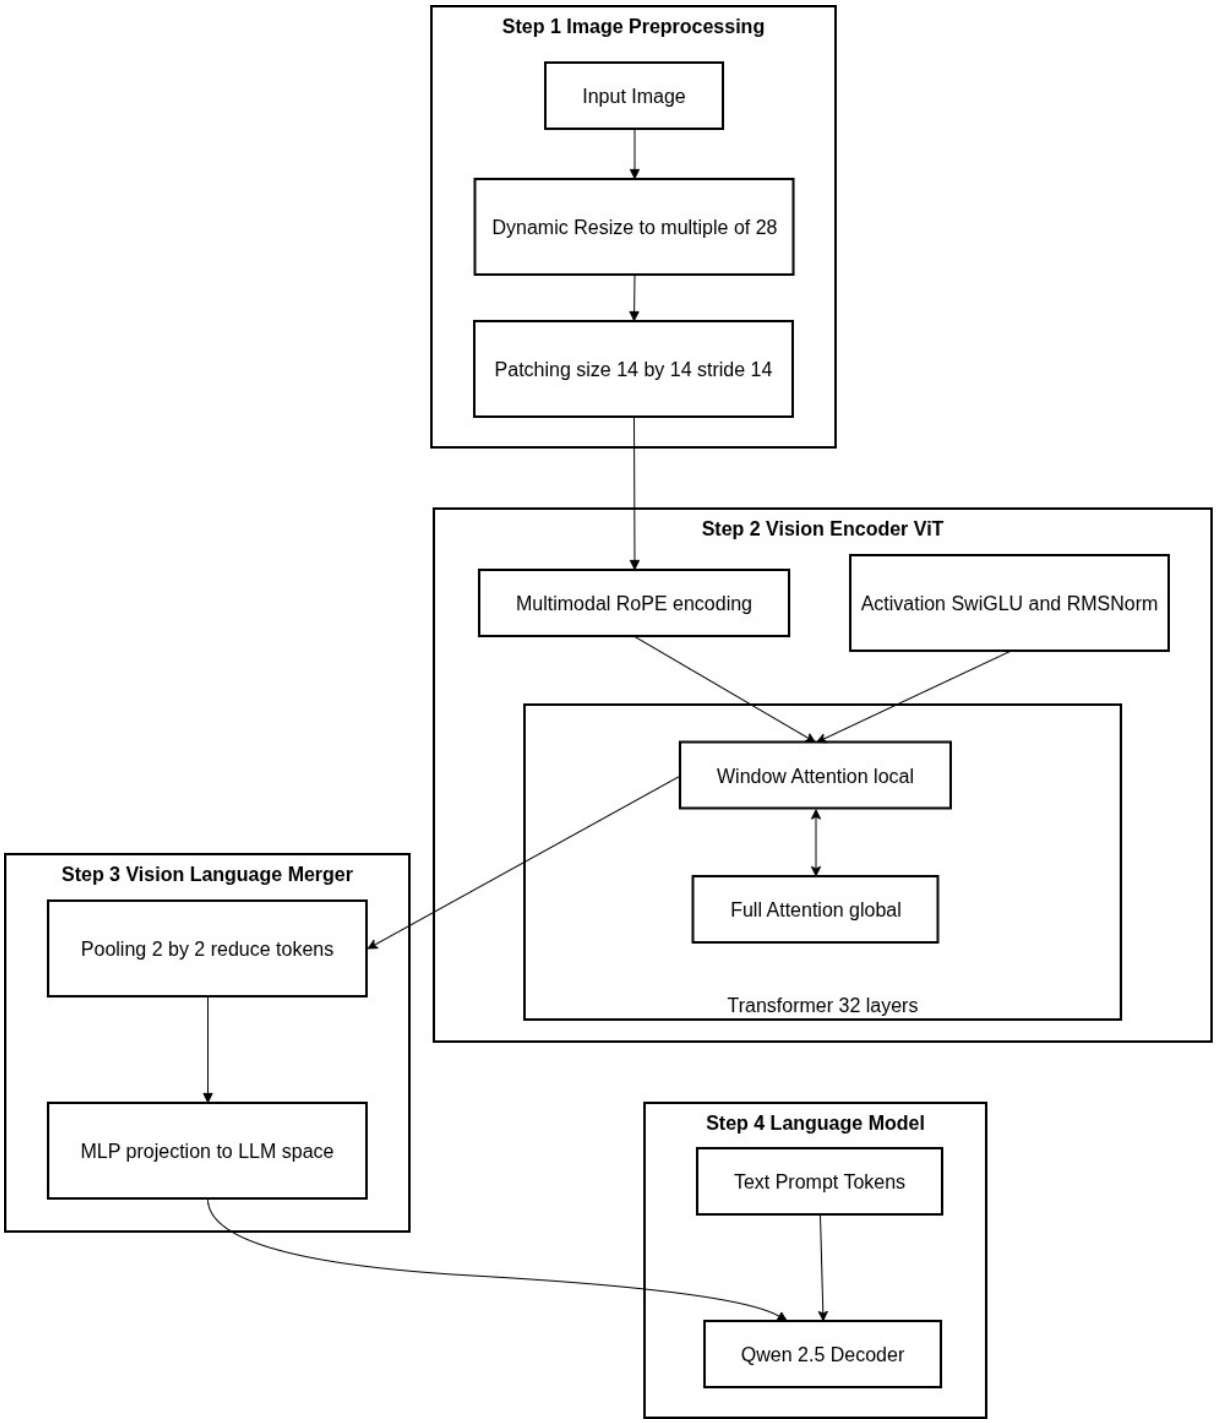

Hình 3: **Qwen2.5-VL-Architecture**

a. Tiền xử lý hình ảnh (Image Pre-processing)

- *Dynamic Resolution (Độ phân giải động):* Qwen2.5-VL không ép hình ảnh về kích thước cố định 224×224 như các mô hình trước đây. Thay vào đó, hình ảnh được resize sao cho

chiều cao và chiều rộng là bội số của 28, giúp bảo toàn tốt hơn cấu trúc không gian ban đầu.

- *Patching:* Sau khi resize, hình ảnh được chia thành các patch có kích thước 14×14 với stride bằng 14.

b. Bộ mã hóa thị giác (Vision Encoder – ViT) Qwen2.5-VL sử dụng kiến trúc Vision Transformer được thiết kế lại, khởi tạo từ Qwen2-VL ViT với khoảng 675 triệu tham số.

- *M-RoPE (Multimodal Rotary Position Embedding):* Đối với ảnh tĩnh, thành phần Temporal ID được giữ cố định cho tất cả các token, trong khi các ID theo chiều cao và chiều rộng thay đổi tương ứng với vị trí không gian của từng patch.
- *Cơ chế Attention:*
  - *Window Attention:* Được áp dụng ở phần lớn các lớp (ví dụ: lớp 0–6, 8–14, ...). Hình ảnh được chia thành các cửa sổ 8×8 patch (tương đương 112×112 pixel), và attention chỉ được tính toán trong từng cửa sổ nhằm giảm chi phí tính toán xuống mức tuyến tính.
  - *Full Self-Attention:* Được chèn tại các lớp có chỉ số $7, 15, 23, 31$, cho phép mô hình quan sát toàn bộ hình ảnh để tổng hợp thông tin ngữ cảnh toàn cục.

c. Bộ trộn Thị giác – Ngôn ngữ (Vision–Language Merger) Đây là thành phần trung gian giúp nén thông tin thị giác trước khi đưa vào mô hình ngôn ngữ nhằm tăng hiệu quả suy luận.

- *Pooling* 2×2*:* Các đặc trưng của một lưới 2×2 (tương ứng 4 patch liền kề) được gộp thành một vector duy nhất. Ví dụ, nếu ảnh đầu vào tạo ra 1000 patch, sau bước này chỉ còn 250 visual token.
- *MLP Projection:* Một mạng MLP gồm 2 lớp được sử dụng để chiếu vector đặc trưng về cùng kích thước embedding với mô hình ngôn ngữ.

d. Mô hình Ngôn ngữ (LLM)

- Sử dụng kiến trúc Qwen2.5 dạng decoder-only với các phiên bản 3B, 7B và 72B.
- Các visual token sau bước Merger được nối (concatenate) với token văn bản (prompt hệ thống, câu hỏi) để tạo thành chuỗi đầu vào đa phương thức cho quá trình suy luận.

2.2.3 Olm-OCR2.0 Architecture

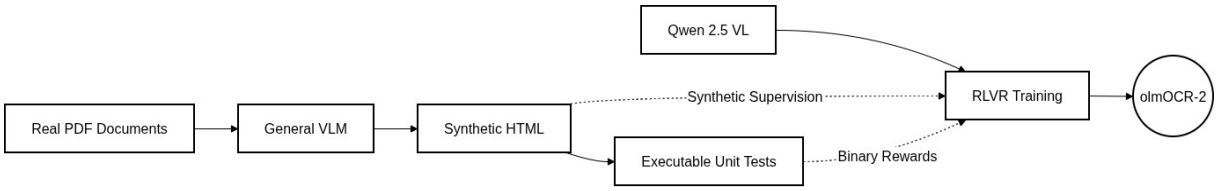

Hình 4: **OLM-OCR2.0-Architecture**

Olm-OCR2.0 là một hệ thống OCR end-to-end dựa trên Vision-Language Model (VLM), được thiết kế nhằm chuyển đổi trực tiếp các trang tài liệu PDF dạng ảnh thành văn bản thuần (plain text / Markdown) theo đúng thứ tự đọc tự nhiên.

Kiến trúc tổng thể của hệ thống gồm 3 phần chính: (i) mô hình nền VLM mạnh, (ii) pipeline sinh dữ liệu tổng hợp dựa trên HTML, và (iii) huấn luyện tăng cường với phần thưởng có thể kiểm chứng (Reinforcement Learning with Verifiable Rewards – RLVR).

a) Base Vision-Language Model Nền tảng của Olm-OCR2.0 là mô hình **Qwen2.5-VL-7B**, một Vision-Language Model decoder-only, hỗ trợ độ phân giải động và khả năng xử lý tài liệu có bố cục phức tạp. Mô hình này được fine-tune theo hướng chuyên biệt cho OCR, cho phép sinh trực tiếp chuỗi văn bản tuyến tính từ ảnh tài liệu đầu vào mà không cần các mô-đun trung gian như phát hiện dòng, cột hay bảng.

b) Synthetic Document Generation Pipeline Để giải quyết bài toán thiếu dữ liệu OCR có nhãn chính xác ở mức cấu trúc, Olm-OCR2.0 sử dụng một pipeline sinh dữ liệu tổng hợp dựa trên HTML:

- Các tài liệu PDF thực được lấy mẫu từ nhiều nguồn khác nhau (bài báo khoa học, tài liệu hành chính, tài liệu nhiều cột).
- Một General VLM được sử dụng để phân tích bố cục trang (layout analysis) và sinh mã HTML tương ứng, phản ánh đầy đủ cấu trúc nội dung như đoạn văn, bảng, công thức toán học, header/footer.
- HTML sinh ra được render lại thành ảnh, tạo thành cặp dữ liệu *(image, HTML)* đóng vai trò ground-truth cấu trúc.

Pipeline này cho phép tạo dữ liệu với bố cục đa dạng, đồng thời giữ được thông tin cấu trúc chính xác ở mức ngữ nghĩa.

c) Executable Unit Tests as Verifiable Rewards Từ HTML ground-truth, hệ thống tự động sinh ra các **unit tests** có thể thực thi, đóng vai trò là phần thưởng nhị phân trong quá trình huấn luyện RL. Các unit tests này kiểm tra nhiều khía cạnh quan trọng của OCR:

- Sự xuất hiện hoặc vắng mặt của các đoạn văn bản cụ thể.
- Thứ tự đọc tự nhiên của các đoạn văn trong tài liệu nhiều cột.
- Quan hệ không gian giữa các ô trong bảng.
- Tính tương đương hình học của công thức toán học sau khi render.

Mỗi unit test trả về kết quả đúng/sai, từ đó tổng hợp thành phần thưởng ở mức trang.

d) RLVR Training with GRPO Olm-OCR2.0 được huấn luyện bằng **Reinforcement Learning with Verifiable Rewards (RLVR)** sử dụng thuật toán Group Relative Policy Optimization (GRPO). Với mỗi trang tài liệu, mô hình sinh ra nhiều mẫu đầu ra (completions), sau đó được chấm điểm dựa trên tỷ lệ unit tests vượt qua. Cách tiếp cận này giúp:

- Tránh các hạn chế của edit distance truyền thống trong đánh giá OCR.
- Cho phép nhiều biểu diễn đầu ra khác nhau nhưng vẫn đúng về mặt ngữ nghĩa.
- Tập trung tối ưu các lỗi OCR quan trọng như bảng, công thức và bố cục nhiều cột.

e) End-to-End OCR Inference Sau khi huấn luyện, Olm-OCR2.0 hoạt động như một hệ thống OCR end-to-end duy nhất: ảnh trang tài liệu được đưa trực tiếp vào VLM và sinh ra văn bản tuyến tính hoàn chỉnh, bao gồm cả nội dung chính, bảng (dạng HTML/Markdown), công thức toán và metadata trang. Toàn bộ pipeline suy luận không phụ thuộc vào các bước tiền xử lý OCR truyền thống, giúp đơn giản hóa hệ thống và cải thiện độ tổng quát.

2.2.4 MinerU2.5: Mô hình tách biệt (Decoupled Architecture)

MinerU2.5 được thiết kế đặc biệt để xử lý tài liệu độ phân giải cao một cách hiệu quả bằng cách tách biệt quá trình phát hiện bố cục (Layout Annalysis) và nhận dạng nội dung (Text Recognition).

Hình 5: **MinerU2.5-Architecture**

(a) **Tổng quan kiến trúc (Architectural Overview)**

MinerU2.5 là một mô hình ngôn ngữ–thị giác (Vision–Language Model, VLM) với tổng số tham số khoảng 1.2B, được thiết kế chuyên biệt cho bài toán phân tích tài liệu độ phân giải cao. Kiến trúc của mô hình được lấy cảm hứng từ Qwen2-VL, tuy nhiên áp dụng chiến lược *tách biệt* (decoupling) nhằm đạt được sự cân bằng giữa hiệu suất tính toán và độ chính xác nhận dạng trong các kịch bản xử lý tài liệu phức tạp.

(b) **Các thành phần cốt lõi (Core Components)**

Mô hình bao gồm ba mô-đun chính hoạt động phối hợp với nhau:

- **Bộ mã hóa thị giác (Vision Encoder):** Sử dụng mô hình NaViT (Native Resolution Vision Transformer) với khoảng 675 triệu tham số, được khởi tạo từ Qwen2-VL. Điểm nổi bật của mô-đun này là khả năng xử lý ảnh ở độ phân giải gốc cùng tỷ lệ khung hình động. Nhóm tác giả loại bỏ cơ chế *window attention* (thường xuất hiện trong Qwen2.5-VL) để tránh suy giảm hiệu suất trên dữ liệu tài liệu, và thay thế bằng cơ chế mã hóa vị trí 2D-RoPE nhằm thích ứng linh hoạt với các kích thước đầu vào khác nhau.
- **Bộ trộn Patch (Patch Merger):** Áp dụng kỹ thuật *pixel-unshuffle* trên các token thị giác liền kề theo cấu trúc 2×2, nhằm nén và tổng hợp đặc trưng thị giác trước khi đưa vào mô hình ngôn ngữ. Thiết kế này giúp tối ưu sự đánh đổi giữa tốc độ suy luận và hiệu năng biểu diễn.
- **Mô hình ngôn ngữ (Language Model Decoder):** Sử dụng Qwen2-Instruct với khoảng 0.5 tỷ tham số. Một cải tiến quan trọng là việc thay thế cơ chế mã hóa vị trí 1D-RoPE truyền thống bằng M-RoPE (Multimodal Rotary Positional Embeddings), giúp mô hình cải thiện khả năng khái quát hóa trên các độ phân giải đa dạng của các vùng ảnh được cắt (image crops).

(c) **Chiến lược phân tích hai giai đoạn (Two-Stage Parsing Strategy)**

Đây là đóng góp kỹ thuật quan trọng nhất của MinerU2.5, giúp mô hình tránh được độ phức tạp tính toán bậc hai $\mathcal{O}(N^2)$ thường gặp trong các mô hình end-to-end truyền thống:

- **Giai đoạn 1 – Phân tích bố cục (Layout Analysis):** Ảnh đầu vào được thay đổi kích thước về dạng thumbnail cố định 1036×1036 pixel. Mục tiêu của giai đoạn này là phân tích nhanh cấu trúc toàn cục (global layout) của tài liệu để xác định vị trí các thành phần như văn bản, bảng biểu và công thức, với chi phí tính toán thấp.
- **Giai đoạn 2 – Nhận dạng nội dung (Content Recognition):** Dựa trên các tọa độ thu được từ giai đoạn phân tích bố cục, mô hình tiến hành cắt các vùng quan trọng trực tiếp từ ảnh gốc ở độ phân giải cao. Các vùng này được đưa vào mô hình ở độ

phân giải gốc (native resolution), với giới hạn tối đa 2048 token cho mỗi vùng, nhằm thực hiện nhận dạng chi tiết (fine-grained recognition).

2.2.5 DeepSeek-OCR 2.0: Mô hình Mã hóa Luồng Nhân Quả Thị Giác (Visual Causal Flow Encoding)

DeepSeek-OCR 2.0 là phiên bản nâng cấp của DeepSeek-OCR, được thiết kế để mô phỏng cơ chế xử lý thông tin thị giác theo luồng nhân quả giống con người. Mô hình này thay thế bộ mã hóa thị giác truyền thống (CLIP) bằng một kiến trúc LLM-style với cơ chế chú ý nhân quả, cho phép sắp xếp lại các token thị giác một cách linh hoạt dựa trên ngữ nghĩa hình ảnh thay vì theo thứ tự raster scan cứng nhắc.

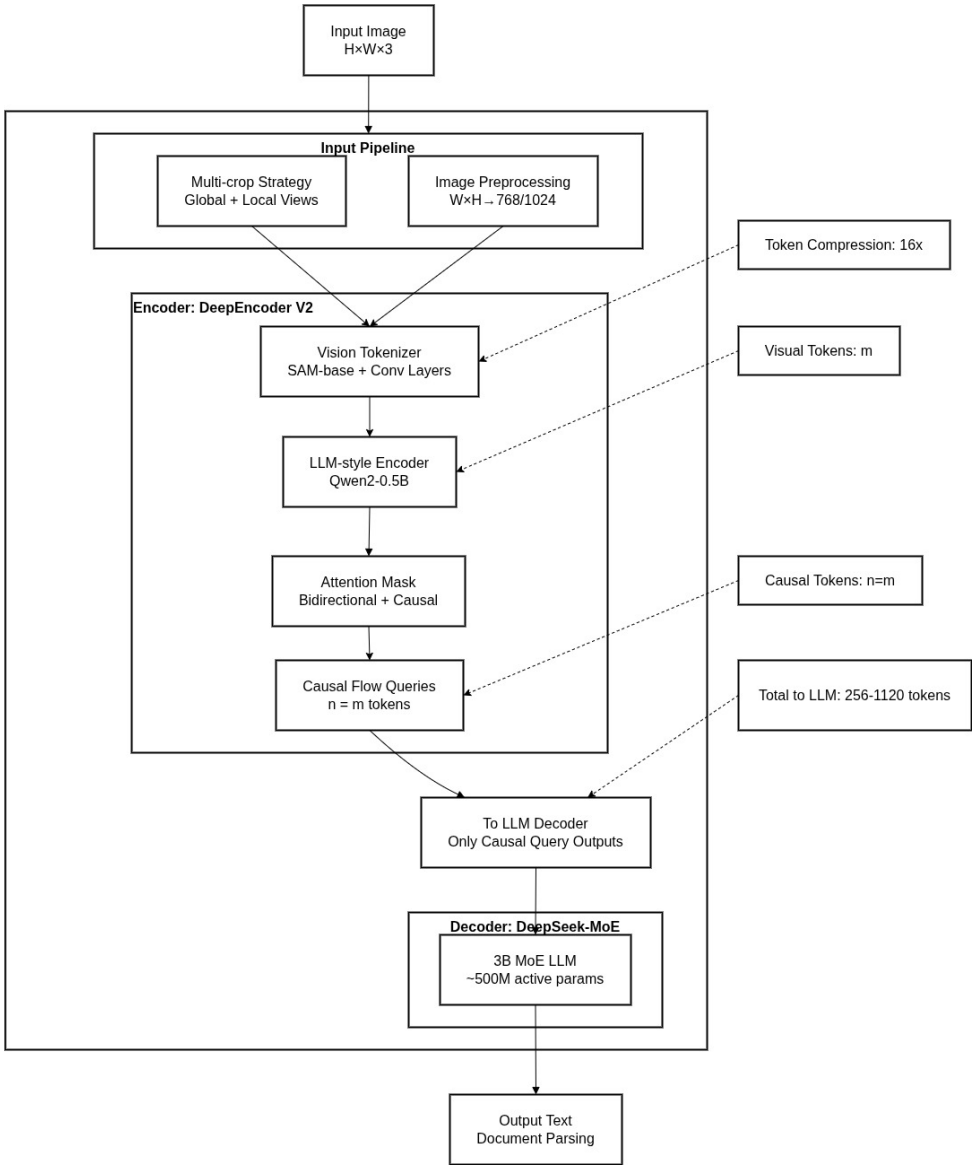

Hình 6: **Kiến trúc DeepSeek-OCR 2.0**

(a) **Tổng quan kiến trúc (Architectural Overview)**

DeepSeek-OCR 2.0 là một mô hình ngôn ngữ–thị giác (Vision–Language Model, VLM) với bộ mã hóa thị giác hoàn toàn mới, DeepEncoder V2, được thiết kế để mô hình hóa luồng xử lý thị giác có nhân quả. Mô hình giữ nguyên bộ giải mã DeepSeek-MoE (3B tham số, 500M tham số active) từ phiên bản trước, tập trung cải thiện khả năng hiểu ngữ nghĩa hình ảnh thông qua việc sắp xếp lại tuần tự các token thị giác. Kiến trúc này lấy cảm hứng từ cơ chế xử lý thị giác của con người, nơi mắt di chuyển theo các mẫu quét linh hoạt dựa trên cấu trúc logic thay vì theo thứ tự không gian cố định.

(b) **Các thành phần cốt lõi (Core Components)**

Mô hình bao gồm các thành phần chính sau:

- **DeepEncoder V2 (Bộ mã hóa thị giác):** Là thành phần đổi mới chính, bao gồm:
  - **Vision Tokenizer:** Sử dụng kiến trúc kết hợp SAM-base (80M tham số) với hai lớp tích chập, thực hiện nén token thị giác 16 lần.
  - **LLM-style Encoder:** Thay thế CLIP ViT bằng kiến trúc ngôn ngữ Qwen2-0.5B (500M tham số) để xử lý token thị giác.
  - **Causal Flow Queries:** Các token truy vấn có thể học được với số lượng bằng số token thị giác (n=m), thực hiện sắp xếp lại token dựa trên ngữ nghĩa.
  - **Attention Mask Kết hợp:** Sử dụng cơ chế chú ý hai chiều (bidirectional) cho token thị giác và chú ý nhân quả (causal) cho token truy vấn.
- **Cơ chế Multi-crop Input:** Áp dụng chiến lược xử lý đa tỷ lệ với global view (1024×1024) và tối đa 6 local views (768×768), tạo ra từ 256 đến 1120 token đầu vào cho LLM.
- **DeepSeek-MoE Decoder:** Giữ nguyên từ phiên bản trước với cấu trúc Mixture-of-Experts 3B tham số, chỉ nhận đầu ra từ các causal flow queries của encoder.

(c) **Cơ chế Luồng Nhân Quả Thị Giác (Visual Causal Flow Mechanism)**

Đây là đóng góp kỹ thuật đột phá của DeepSeek-OCR 2.0, cho phép mô hình thực hiện lý luận 2D thông qua hai tầng lý luận nhân quả 1D:

- **Tầng 1 – Sắp xếp lại Token (Token Reordering):** DeepEncoder V2 thực hiện lý luận logic đọc bằng cách sắp xếp lại thông tin thị giác thông qua causal flow queries. Mỗi token truy vấn có thể chú ý đến tất cả token thị giác và các token truy vấn trước đó, tạo ra một trình tự được sắp xếp theo quan hệ nhân quả.
- **Tầng 2 – Lý luận Tự hồi quy (Autoregressive Reasoning):** Bộ giải mã LLM thực hiện lý luận tự hồi quy trên trình tự đã được sắp xếp, tương tự như xử lý ngôn ngữ tự

nhiên. Cách tiếp cận này phá vỡ ràng buộc không gian 2D truyền thống bằng cách chuyển đổi bài toán hiểu hình ảnh thành hai bài toán lý luận nhân quả 1D bổ trợ.

- **Cơ chế Attention Đặc biệt:** Attention mask của DeepEncoder V2 được thiết kế với hai vùng riêng biệt: vùng bên trái cho phép token thị giác tương tác đầy đủ (tương tự ViT), trong khi vùng bên phải áp dụng mask tam giác (tương tự LLM decoder) cho các causal flow queries, tạo ra luồng xử lý nhân quả tuần tự.

(d) **Quy trình Huấn luyện Ba Giai đoạn (Three-Stage Training Pipeline)**

DeepSeek-OCR 2.0 được huấn luyện theo quy trình ba giai đoạn nhằm tối ưu hóa hiệu quả:

- **Giai đoạn 1 – Tiền huấn luyện DeepEncoder V2:** Huấn luyện vision tokenizer và LLM-style encoder với mục tiêu mô hình hóa ngôn ngữ, sử dụng bộ giải mã nhẹ để tối ưu hóa chung.
- **Giai đoạn 2 – Nâng cao biểu diễn truy vấn (Query Enhancement):** Tích hợp DeepEncoder V2 với DeepSeek-LLM, đóng băng vision tokenizer và đồng thời tối ưu hóa LLM encoder và decoder để nâng cao khả năng biểu diễn của các truy vấn.
- **Giai đoạn 3 – Huấn luyện tiếp LLM:** Đóng băng toàn bộ tham số của DeepEncoder V2, chỉ cập nhật tham số của DeepSeek-LLM để tăng tốc độ huấn luyện và giúp LLM hiểu rõ hơn các token thị giác đã được sắp xếp lại.

2.2.6 LightOn-OCR 2.0: Mô hình Ngôn ngữ-Thị giác End-to-End Nhẹ và Hiệu quả (Lightweight End-to-End VLM)

LightOn-OCR 2.0 là một mô hình ngôn ngữ-thị giác (Vision–Language Model, VLM) cực kỳ nhỏ gọn với chỉ 1 tỷ tham số, được thiết kế để thực hiện nhận dạng ký tự quang học (OCR) trực tiếp từ pixel đến văn bản có cấu trúc mà không cần các pipeline phức tạp nhiều tầng. Mô hình này tập trung vào sự cân bằng giữa hiệu suất cao, tốc độ xử lý nhanh và khả năng triển khai thực tế trên các tài liệu in ấn phức tạp như tài liệu khoa học, bảng biểu và văn bản đa ngôn ngữ.

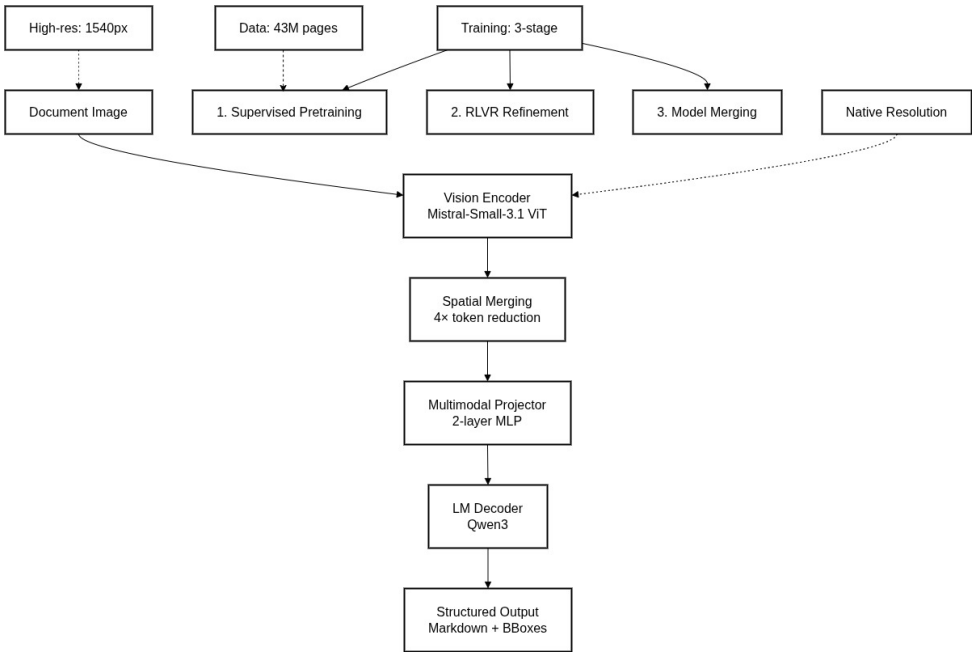

Hình 7: **Kiến trúc LightOn-OCR 2.0**

(a) **Tổng quan kiến trúc (Architectural Overview)**

LightOn-OCR 2.0 là một mô hình end-to-end thống nhất với kiến trúc ba thành phần chính: bộ mã hóa thị giác, bộ chiếu đa phương thức (multimodal projector) và bộ giải mã ngôn ngữ. Với chỉ 1 tỷ tham số, mô hình này đạt được hiệu suất state-of-the-art trên benchmark OImOCR-Bench trong khi nhỏ hơn 9 lần và nhanh hơn đáng kể so với các mô hình hiệu suất cao trước đó. Điểm đặc biệt của LightOn-OCR 2.0 là khả năng dự đoán tọa độ bounding box cho các hình ảnh nhúng trong tài liệu, mở rộng chức năng OCR truyền thống thành một hệ thống hiểu tài liệu toàn diện.

(b) **Các thành phần cốt lõi (Core Components)**

Mô hình bao gồm ba mô-đun chính hoạt động liền mạch:

- **Bộ mã hóa thị giác (Vision Encoder):** Sử dụng kiến trúc Vision Transformer (ViT) được khởi tạo từ trọng số đã tiền huấn luyện của Mistral-Small-3.1. Encoder này có khả năng xử lý ảnh ở độ phân giải gốc (native resolution), bảo toàn cấu trúc không gian của tài liệu—một yếu tố quan trọng cho việc xử lý các tài liệu có tỷ lệ khung hình đa dạng và chi tiết typography tinh tế.
- **Bộ chiếu đa phương thức (Multimodal Projector):** Để kết nối phương thức thị giác và ngôn ngữ đồng thời kiểm soát độ dài chuỗi, mô hình sử dụng một MLP 2 lớp với hàm kích hoạt GELU. Trước khi chiếu, mô hình áp dụng cơ chế hợp nhất không gian (spatial merging) với hệ số 2, nhóm các patch 2×2 và giảm số lượng token thị giác xuống 4 lần. Thiết kế này giữ cho tổng số token ở mức có thể xử lý được với đầu vào độ phân giải cao trong khi vẫn bảo toàn đủ độ chi tiết không gian.

- **Bộ giải mã ngôn ngữ (Language Model Decoder):** Được khởi tạo từ Qwen3 đã tiền huấn luyện. Bộ giải mã tạo ra một biểu diễn tuyến tính hóa duy nhất của trang tài liệu, bảo toàn thứ tự đọc trong khi phát ra các token có cấu trúc cho các phần tử phi văn bản (ví dụ: ! [image] (image_N.png)). Để đơn giản hóa giao diện giữa các phương thức, mô hình loại bỏ các token ngắt ảnh và kết thúc ảnh, chỉ điều kiện hóa bộ giải mã trên một khối token thị giác liên tục duy nhất.

(c) **Quy trình Huấn luyện Ba Giai đoạn (Three-Stage Training Pipeline)**

LightOn-OCR 2.0 được huấn luyện theo một quy trình tinh vi gồm ba giai đoạn để tối ưu hóa cả chất lượng OCR và khả năng định vị hình ảnh:

- **Giai đoạn 1 – Tiền huấn luyện có giám sát (Supervised Pretraining):** Huấn luyện trên tập dữ liệu hỗn hợp quy mô lớn gồm 43 triệu trang tài liệu, được tạo ra thông qua quá trình chưng cất (distillation) từ mô hình giáo viên mạnh Qwen3-VL-235B. Dữ liệu bao gồm tài liệu khoa học, scan và văn bản tiếng Pháp, với độ phân giải huấn luyện tối đa 1540 pixel.
- **Giai đoạn 2 – Tinh chỉnh với RLVR (Reinforcement Learning with Verifiable Rewards):** Áp dụng học tăng cường với phần thưởng có thể xác minh để tối ưu hóa cho các lỗi OCR khó xử lý bằng học có giám sát thông thường, bao gồm: các vòng lặp lặp lại (repetition loops), lỗi hiển thị công thức toán học, và các ràng buộc nhất quán nhạy cảm với bố cục. Phần thưởng được tính toán thông qua các kiểm tra tự động có thể đánh giá xác định trên đầu ra của mô hình.
- **Giai đoạn 3 – Hợp nhất mô hình trong không gian trọng số (Weight-space Model Merging):** Sử dụng các kỹ thuật nhẹ trong không gian trọng số như tính trung bình checkpoint và hợp nhất số học tác vụ (task-arithmetic merging) để kết hợp các lợi ích bổ sung từ các lần chạy khác nhau và kiểm soát sự đánh đổi giữa chất lượng OCR và độ chính xác của bounding box.

(d) **Khả năng Định vị Hình ảnh (Image Localization Capability)**

Một đóng góp đáng chú ý của LightOn-OCR 2.0 là mở rộng định dạng đầu ra để dự đoán bounding box cho các hình ảnh nhúng trong tài liệu. Định dạng đầu ra được mở rộng thành: `![image](image_N.png)x1,y1,x2,y2`, trong đó tọa độ được chuẩn hóa trong khoảng [0, 1000]. Để tránh làm giảm chất lượng OCR khi thêm khả năng này, nhóm tác giả giới thiệu giám sát tọa độ trong quá trình tiền huấn luyện thông qua chiến lược "resume"và sau đó tinh chỉnh định vị bằng RLVR với mục tiêu dựa trên IoU (Intersection over Union).

(e) **Tối ưu hóa Từ vựng (Vocabulary Optimization)**

LightOn-OCR 2.0 thực hiện tỉa từ vựng dựa trên tần suất sử dụng cho các tài liệu tiếng Anh/Pháp, giảm kích thước từ vựng từ 151k token xuống còn 32k hoặc 16k token trong khi vẫn duy trì tính toàn vẹn của tokenizer. Biến thể 32k đạt được sự cân bằng tốt nhất giữa tốc độ và độ chính xác: tăng tốc suy luận 11.6% trong khi giữ lại 96% hiệu suất cơ sở, giảm đáng kể tham số mô hình và tăng hiệu quả tính toán.

3 Đề xuất kiến trúc mô hình

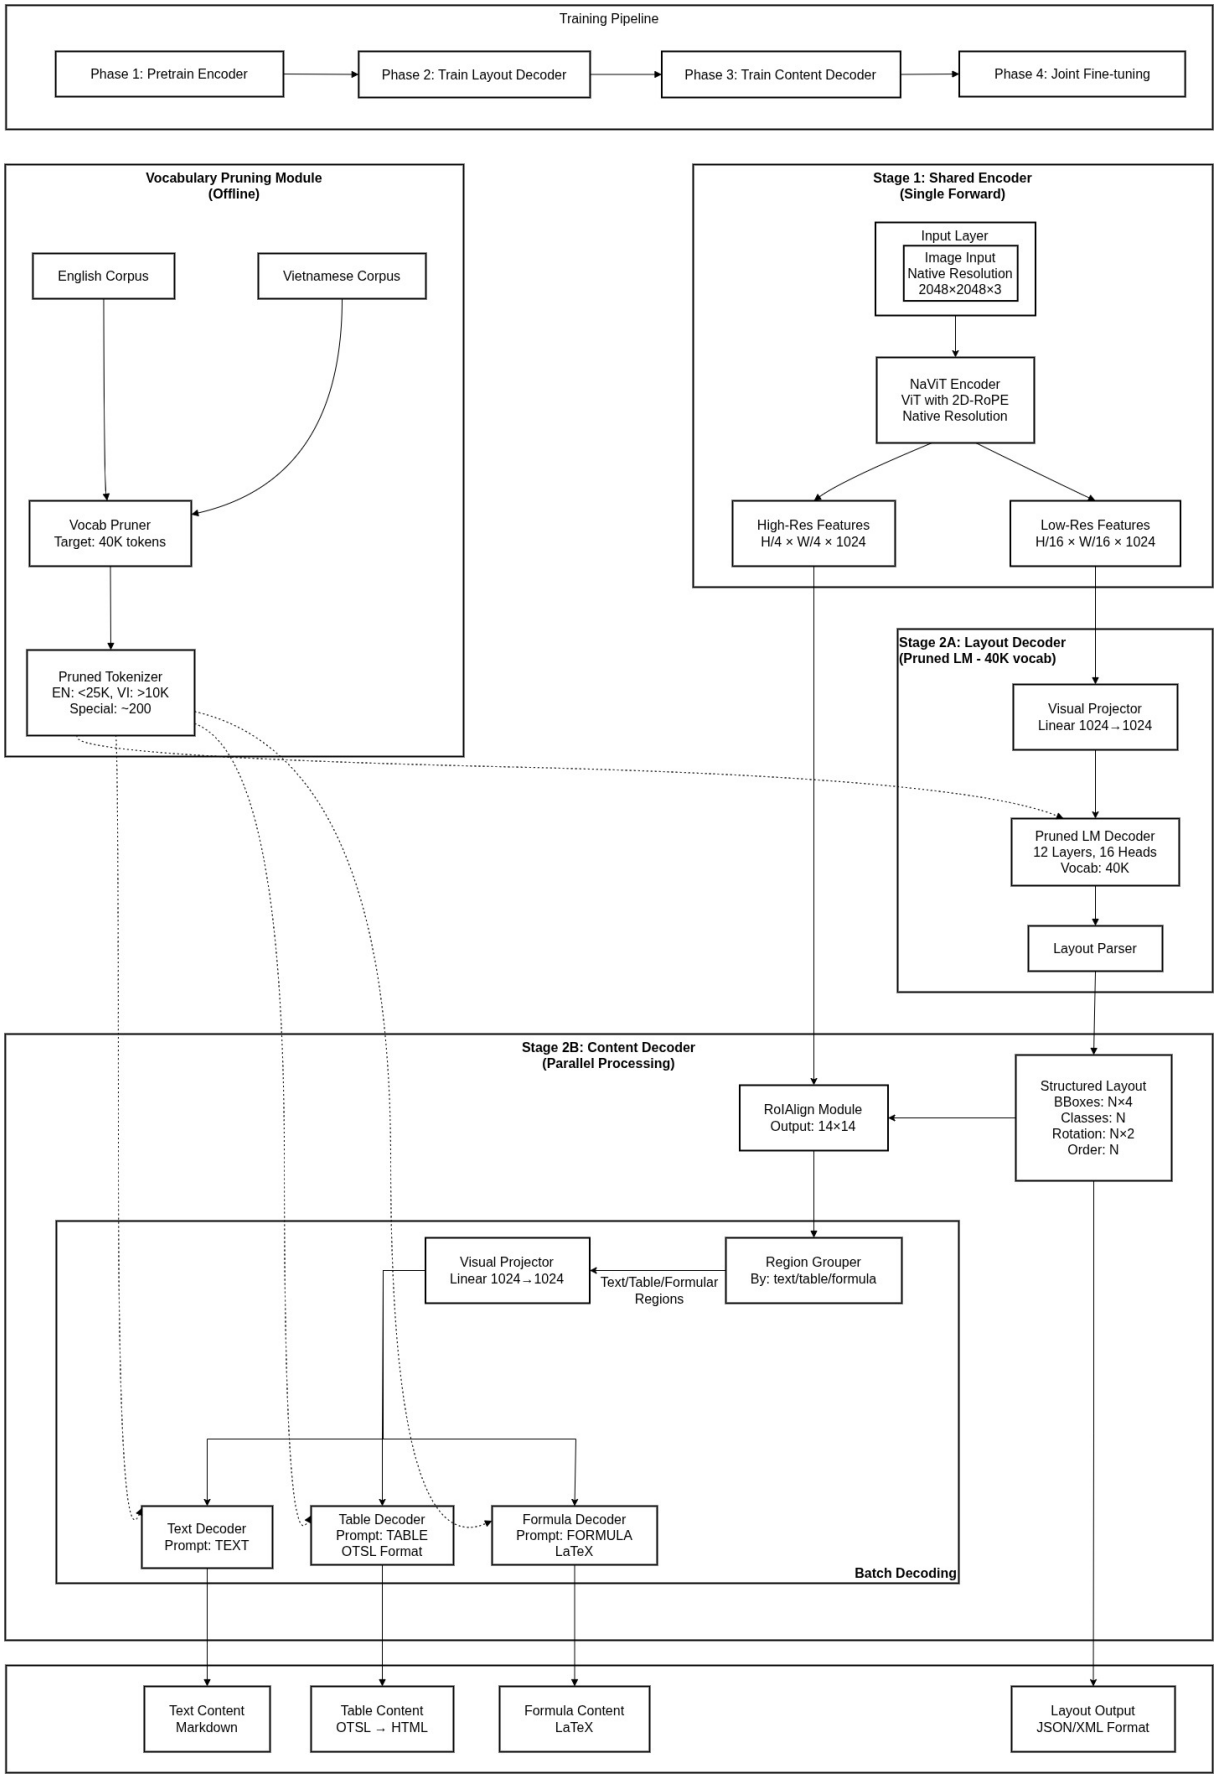

Hình 8: **Proposal Architecture**

3.1 Tổng quan kiến trúc

Đề xuất một kiến trúc Vision-Language Model chuyên biệt cho bài toán phân tích tài liệu hai giai đoạn với tối ưu hóa cho ngôn ngữ Anh và Việt.

Kiến trúc này có các ưu điểm sau:

(1) khả năng phân tích layout chính xác và phân giải cao của MinerU2.5,

(2) hiệu quả tính toán và tối ưu vocabulary. Mô hình được thiết kế theo hướng tiếp cận single-encoder, dual-decoder với feature pyramid extraction, chỉ yêu cầu một lượt truyền forward qua encoder nhưng vẫn đảm bảo khả năng phân tích hai giai đoạn: layout analysis và content recognition.

Kiến trúc tổng thể bao gồm ba thành phần chính:

(i) Shared Multi-Scale Encoder trích xuất đặc trưng đa độ phân giải từ ảnh đầu vào,

(ii) Layout Decoder với pruned vocabulary phân tích cấu trúc tài liệu, và

(iii) Parallel Content Decoder nhận diện nội dung theo từng loại region. Kiến trúc này áp dụng vocabulary pruning chuyên biệt cho ngôn ngữ Anh và Việt, giảm kích thước vocabulary từ 151K tokens xuống còn 40K tokens (dự kiến), qua đó cải thiện đáng kể tốc độ inference và giảm yêu cầu bộ nhớ mà vẫn duy trì độ chính xác cao cho hai ngôn ngữ mục tiêu.

3.2 Các thành phần kiến trúc

3.2.1 Shared Multi-Scale Encoder

Bộ mã hóa này sử dụng kiến trúc NaViT (Native Vision Transformer) với 2D Rotary Position Embedding (2D-RoPE), cho phép xử lý ảnh ở độ phân giải gốc (native resolution) mà không cần resize trước. Thay vì thực hiện hai lượt truyền forward riêng biệt cho layout analysis và content recognition như trong MinerU2.5, encoder chỉ chạy một lần duy nhất và trích xuất đồng thời hai loại đặc trưng ở các độ phân giải khác nhau thông qua cơ chế feature pyramid:

High-resolution features ($H/4 \times W/4 \times 1024$): Được trích xuất từ các layer sâu của encoder, giữ lại chi tiết cấp độ pixel cần thiết cho việc nhận diện ký tự nhỏ, công thức toán học phức tạp, và cấu trúc bảng chi tiết. Các features này được sử dụng ở giai đoạn content recognition.

Low-resolution features ($H/16 \times W/16 \times 1024$): Được trích xuất từ các layer giữa của encoder, cung cấp tầm nhìn toàn cục (global view) của trang tài liệu với kích thước đã được downsampled tự nhiên bởi các phép tích chập trong encoder. Các features này đủ chi tiết để phân tích layout nhưng không gây lãng phí tính toán.

Việc sử dụng chung encoder cho cả hai nhiệm vụ không chỉ giảm thời gian tính toán khoảng 50% (dự kiến) so với kiến trúc hai lượt forward, mà còn đảm bảo tính nhất quán giữa đặc trưng layout và content, tránh hiện tượng mismatch có thể xảy ra khi sử dụng hai encoder riêng biệt.

3.2.2 Vocabulary Pruning Module

Đây là thành phần tối ưu hóa chuyên biệt cho ngôn ngữ Anh và Việt, được thực hiện offline trước khi training mô hình chính. Module này thực hiện phân tích thống kê trên hai kho ngữ liệu lớn tiếng Anh và tiếng Việt để xác định tập từ vựng tối ưu:

Phân tích tần suất token: Thống kê tần suất xuất hiện của các token trong kho ngữ liệu đa lĩnh vực (học thuật, hành chính, báo chí, kinh doanh).

Giữ lại tokens thiết yếu:

Tiếng Anh: 25.000 tokens phổ biến nhất (62.5% vocabulary)

Tiếng Việt: 10.000 tokens đặc trưng, bao gồm các ký tự có dấu trong các khoảng Unicode: U+00C0-U+00FF (Latin-1 Supplement), U+0100-U+017F (Latin Extended-A), U+1E00-U+1EFF (Latin Extended Additional)

Special tokens: 200 tokens điều khiển (BOS, EOS, padding, v.v.)

Common symbols: 4.800 tokens cho số, ký hiệu toán học, ký tự đặc biệt

Loại bỏ tokens không liên quan: Các tokens cho ngôn ngữ khác (CJK, Arabic, Cyrillic) và các tokens hiếm gặp được loại bỏ, giảm kích thước vocabulary từ 151K xuống 40K tokens (giảm 73.5

Pruned vocabulary này được sử dụng chung cho cả Layout Decoder và Content Decoder, mang lại các lợi ích: (i) giảm 75

3.2.3 Layout Decoder

Layout Decoder là một mô hình ngôn ngữ transformer được huấn luyện trên pruned vocabulary (40K tokens). Decoder này nhận đầu vào là low-resolution features từ encoder và thực hiện các nhiệm vụ:

Bounding box detection: Xác định tọa độ (x1, y1, x2, y2) của từng region trên trang, được chuẩn hóa về tọa độ tương đối [0, 1000].

Region classification: Phân loại từng region vào các hạng mục: tiêu đề (title), văn bản (text), bảng (table), công thức (formula), hình ảnh (figure), header, footer, v.v.

Rotation prediction: Dự đoán góc xoay của region dưới dạng sin/cos của góc, cho phép xử

lý các tài liệu bị scan nghiêng.

Reading order assignment: Gán chỉ số thứ tự đọc cho từng region, sử dụng cơ chế attention của transformer để hiểu mối quan hệ không gian giữa các regions, đặc biệt quan trọng cho các layout phức tạp như multi-column, text wrapping.

Output của Layout Decoder được định dạng theo cấu trúc XML-like, ví dụ: <bbox>100 200 300 400</bbox><class>text</class><rotation>0 1</rotation><order>2</order>. Việc sử dụng LM cho layout analysis (thay vì các phương pháp heuristic) cho phép mô hình học các quy tắc phức tạp về cấu trúc tài liệu và duy trì khả năng hiểu ngữ nghĩa.

3.2.4 RoIAlign Module

Sau khi có được bounding boxes từ Layout Decoder, RoIAlign Module thực hiện trích xuất đặc trưng tương ứng cho từng region từ high-resolution features. Khác với phương pháp crop và resize truyền thống (có thể làm biến dạng aspect ratio), RoIAlign sử dụng bilinear interpolation để lấy mẫu giá trị feature tại các vị trí tọa độ thập phân, đảm bảo:

Spatial precision: Không làm tròn tọa độ, giữ nguyên độ chính xác vị trí đặc biệt quan trọng cho text nhỏ và công thức.

Differentiability: Cho phép gradient backpropagation qua module, hỗ trợ training end-to-end.

Size invariance: Output luôn có kích thước cố định (14×14×1024) bất kể kích thước region đầu vào, tạo đầu vào đồng nhất cho các content decoder.

RoIAlign thực hiện với spatial scale factor 1/4 (do high-resolution features có kích thước bằng 1/4 ảnh gốc) và sampling ratio 2 (4 điểm mẫu mỗi bin). Module này chính là cầu nối hiệu quả giữa layout analysis và content recognition, cho phép tập trung tính toán vào các vùng quan trọng thay vì xử lý toàn bộ ảnh.

3.2.5 Parallel Content Decoder

Thay vì xử lý tuần tự từng region như trong MinerU2.5, Parallel Content Decoder thực hiện batch processing theo loại region để tối ưu hóa inference:

Region grouping: Các regions được nhóm theo loại (text, table, formula) dựa trên kết quả classification từ Layout Decoder.

Batch decoding: Mỗi nhóm regions cùng loại được xử lý đồng thời trong một batch:

Text regions: Sử dụng prompt "<|text|>", decoder sinh ra nội dung văn bản dưới dạng Markdown với encoding UTF-8 cho tiếng Việt có dấu.

Table regions: Sử dụng prompt "<|table|>", decoder sinh ra cấu trúc bảng dưới dạng OTSL (Optimized Table Structure Language) - một định dạng trung gian tối ưu với 5 token cấu trúc, sau đó được chuyển đổi tự động sang HTML.

Formula regions: Sử dụng prompt "<|formula|>", decoder sinh ra công thức toán học dưới dạng LaTeX, với cơ chế Atomic Decomposition Recombination (ADR) cho các công thức nhiều dòng phức tạp.

Shared architecture: Cả ba decoder con đều chia sẻ kiến trúc transformer. Việc sharing parameters giúp giảm kích thước mô hình và tăng khả năng transfer learning giữa các tasks.

Vietnamese-specific processing: Đối với text regions tiếng Việt, decoder được huấn luyện đặc biệt để xử lý các ký tự có dấu và các lỗi OCR phổ biến trong tiếng Việt (như nhầm lẫn giữa "a"và "â", "d"và "đ").

Cơ chế parallel decoding này giảm đáng kể thời gian inference, đặc biệt với các tài liệu có nhiều regions cùng loại, đồng thời vẫn đảm bảo chất lượng nhận diện nhờ việc xử lý chuyên biệt cho từng loại nội dung.

3.3 Training Pipeline

Quy trình huấn luyện được chia thành bốn giai đoạn tuần tự:

Phase 1: Encoder Pretraining: Huấn luyện Shared Multi-Scale Encoder trên 7 triệu trang tài liệu Anh-Việt với mục tiêu reconstruction (masked image modeling), tập trung vào việc học biểu diễn đa độ phân giải hiệu quả.

Phase 2: Layout Decoder Training: Cố định encoder, huấn luyện Layout Decoder trên dataset có annotation layout (500K trang) với multi-task loss cho bounding box, classification, rotation, và reading order.

Phase 3: Content Decoder Training: Cố định encoder và Layout Decoder, huấn luyện riêng rẽ từng Content Decoder (text, table, formula) trên các dataset chuyên biệt với prompt-based instruction tuning.

Phase 4: Joint Fine-tuning: Huấn luyện end-to-end toàn bộ kiến trúc trên tập dữ liệu tổng hợp với loss function kết hợp, sử dụng gradient checkpointing để tiết kiệm bộ nhớ.

Toàn bộ quá trình huấn luyện sử dụng pruned vocabulary 40K tokens ngay từ đầu, đảm bảo tính nhất quán giữa training và inference. Các kỹ thuật optimization như mixed precision training (BF16), gradient accumulation, và learning rate warmup được áp dụng để ổn định quá trình huấn luyện.

4 Dataset Engine

Hệ thống Dataset Engine được thiết kế để xây dựng bộ dữ liệu huấn luyện chất lượng cao cho mô hình Proposal Model, kết hợp các phương pháp tiên tiến từ MinerU2.5, LightOnOCR và các hệ thống VLM hiện đại. Engine hoạt động theo pipeline ba giai đoạn với cơ chế quality control đa tầng, đặc biệt tập trung vào xử lý song ngữ Anh-Việt.

4.1 Tổng quan Pipeline

Hệ thống Dataset Engine tuân theo kiến trúc modular với ba giai đoạn chính như minh họa trong Hình **??**. Mỗi giai đoạn đều tích hợp cơ chế đảm bảo chất lượng và tối ưu hóa cho đặc thù ngôn ngữ Anh-Việt.

4.2 Giai đoạn 1: Data Curation và Collection

Giai đoạn này tập trung vào việc thu thập và làm sạch dữ liệu thô từ nhiều nguồn khác nhau, với mục tiêu xây dựng kho dữ liệu cân bằng và đa dạng.

4.2.1 Nguồn dữ liệu

Bảng 1: Các nguồn dữ liệu chính cho bộ song ngữ Anh–Việt

Nguồn	**Đặc điểm**	**Số lượng ước tính**	**Công cụ xử lý**
PDF Association Dataset	Tài liệu học thuật tiếng Anh chất lượng cao	2M trang	PDFExtract-Kit, Camelot
arXiv Corpus	Bài báo khoa học với mã nguồn LaTeX	3M trang	nvpdftex, PDFMiner
Vietnamese Gov Documents	Văn bản hành chính, pháp luật	500K trang	VnCoreNLP, PyPDF2
Vietnamese News Portals	Báo điện tử đa thể loại	300K trang	Newspaper3k, BeautifulSoup
Scanned Document Collections	Tài liệu scan từ thư viện	200K ảnh	OpenCV, Scikit-image
Synthetic Data	Tạo từ template và augmentation	100K trang	SynthDoG, DocCreator

4.2.2 Tiêu chí lựa chọn và cân bằng

- **Cân bằng ngôn ngữ**: Tỷ lệ 60% Anh - 40% Việt, phản ánh nhu cầu thực tế
- **Đa dạng thể loại**: Học thuật (30%), Hành chính (25%), Báo chí (20%), Kinh doanh (15%), Khác (10%)
- **Phân bố độ phức tạp**: Đơn giản (40%), Trung bình (35%), Phức tạp (25%)
- **Độ phân giải ảnh**: Từ 72 DPI đến 600 DPI, tập trung ở 200-300 DPI

4.2.3 Công cụ xử lý

Bảng 2: Công cụ xử lý dữ liệu thô

Công cụ	Chức năng	Ứng dụng cụ thể
PDFExtract-Kit	Trích xuất nội dung từ tệp PDF	Xử lý PDF có text layer
nvpdftex	Biên dịch tài liệu LaTeX sang ảnh và annotation	Tạo dữ liệu huấn luyện từ arXiv
PyPDF2 / PDFMiner	Phân tích metadata và cấu trúc PDF	Phân loại và tiền xử lý tài liệu tự động
OpenCV + Scikit-image	Xử lý ảnh tài liệu scan	Deskew, khử nhiễu, nhị phân hóa ảnh
VnCoreNLP	Xử lý ngôn ngữ tự nhiên tiếng Việt	Tokenization, POS tagging
SynthDoG	Sinh dữ liệu tài liệu tổng hợp	Data augmentation, sinh các hard cases

4.3 Giai đoạn 2: Automated Annotation Pipeline

Pipeline tự động hóa annotation sử dụng ensemble của nhiều mô hình mạnh để tạo nhãn chất lượng cao, kết hợp với cơ chế cross-validation.

4.3.1 Ensemble Model Strategy

Đề xuất sử dụng ba mô hình mạnh đồng thuận là phương pháp tối ưu, với các ưu điểm sau:

- **Tăng độ tin cậy**: Khi ba mô hình độc lập cho kết quả giống nhau, xác suất đúng > 99%
- **Phát hiện uncertainty**: Bất đồng giữa các model chỉ ra samples khó, cần human review
- **Tận dụng strengths khác nhau**: Mỗi model có điểm mạnh riêng (layout, table, formula)

- **Giảm bias**: Ensemble giảm bias đặc thù của từng model

4.3.2 Model Selection cho Ensemble

Bảng 3: Ba mô hình được chọn cho annotation ensemble

Model	Điểm mạnh	Tham số	Lý do lựa chọn
Gemini-2.5 Pro	OCR chính xác, khả năng hiểu ngữ cảnh tài liệu phức tạp	N/A	Hiệu năng SOTA cho bài toán document understanding tổng quát
Qwen2.5-VL-72B	Hỗ trợ độ phân giải gốc (native resolution), đa ngôn ngữ	72B	Mô hình mã nguồn mở mạnh nhất, hỗ trợ tốt tiếng Việt
MinerU2.5	Phân tích bố cục và parsing bảng chính xác	1.2B	Mô hình chuyên biệt cho document parsing, dễ tích hợp

4.3.3 Quy trình Annotation Tự động

1. **Parallel Inference**: Chạy đồng thời cả ba model trên từng document
2. **Consistency Check**: So sánh kết quả bằng metrics:
   - Layout: PageIoU > 0.9
   - Text: CER (Character Error Rate) < 0.02
   - Table: TEDS > 0.95
   - Formula: CDM > 0.9
3. **Automatic Acceptance**: Samples đạt consensus ở tất cả metrics → tự động chấp nhận
4. **Flagging Uncertainty**: Samples có bất đồng → đánh dấu cho human review
5. **Confidence Scoring**: Gán confidence score dựa trên độ nhất quán

4.3.4 Công cụ và Infrastructure

Bảng 4: Công cụ hỗ trợ automated annotation

Công cụ	Chức năng	Integration
vLLM	High-throughput inference	Batch processing cho local models
Google AI API	Gemini API access	REST API integration
Celery + Redis	Task queue và distributed processing	Quản lý parallel jobs
MLflow	Experiment tracking và logging	Theo dõi model performance
Prometheus + Grafana	Monitoring hệ thống	Giám sát resource usage

4.4 Giai đoạn 3: Human-in-the-Loop Refinement

Giai đoạn tinh chỉnh với sự tham gia của con người, tập trung vào các samples khó và đảm bảo chất lượng cuối cùng.

4.4.1 Workflow Human Review

4.4.2 Priority Queue và Sample Selection

Hệ thống tự động ưu tiên samples cần human review:

Bảng 5: Tiêu chí ưu tiên cho human review

Mức độ ưu tiên	Tiêu chí	Xử lý
Cao (P0)	Bất đồng cả 3 model, confidence < 0.5	Human review ngay
Trung bình (P1)	Bất đồng 2/3 model, confidence 0.5-0.7	Review trong 24h
Thấp (P2)	Minor discrepancies, confidence > 0.7	Batch review
Tự động (P3)	Full consensus, confidence > 0.95	Auto-accept

4.4.3 AI-Assisted Annotation Tool

Xây dựng công cụ annotation hỗ trợ AI:

- **Auto-suggestion**: Hiển thị kết quả từ cả ba model, highlight differences
- **Smart Merge**: Gợi ý merge strategy dựa trên confidence scores
- **Consistency Check**: Tự động phát hiện inconsistency trong annotation
- **Version Control**: Lưu lại lịch sử chỉnh sửa và rationale
- **Keyboard Shortcuts**: Tối ưu workflow cho annotators

4.4.4 Quality Control Framework

Hệ thống đảm bảo chất lượng đa tầng:

Bảng 6: Các lớp quality control

Lớp QC	Phương pháp	Tần suất	Chỉ tiêu
Real-time	Rule-based validation	100% samples	Format consistency
Daily	Random sampling (5%)	Hàng ngày	Accuracy > 98%
Weekly	Cross-annotator agreement	Hàng tuần	Inter-annotator > 0.9
Monthly	Benchmark evaluation	Hàng tháng	So SOTA models

4.4.5 Annotator Training và Calibration

- **Training Program**: 2 tuần training cho annotators mới
- **Calibration Sessions**: Hàng tuần để đảm bảo consistency
- **Feedback Loop**: Nhận xét từ model performance → cập nhật guidelines
- **Performance Metrics**: Theo dõi accuracy, speed, consistency

4.5 Đánh giá Phương pháp Ensemble + Human-in-the-Loop

4.5.1 Ưu điểm của Phương pháp Đề xuất

Phương pháp sử dụng ba model lớn kết hợp human-in-the-loop mang lại nhiều lợi ích:

Bảng 7: So sánh phương pháp annotation

Phương pháp	Độ chính xác	Chi phí	Tốc độ
Single Model	85-90%	Thấp	Cao
Dual Model Consensus	92-95%	Trung bình	Trung bình
Triple Model Consensus (Đề xuất)	**98-99%**	Cao	Thấp
Full Human Annotation	99.5%	Rất cao	Rất thấp

4.5.2 Tính khả thi và Hiệu quả kinh tế

- **Hiệu quả chi phí**: Tự động hóa 80-90% samples, chỉ 10-20% cần human review
- **Chất lượng đảm bảo**: Confidence scoring cho phép kiểm soát chất lượng
- **Khả năng mở rộng**: Dễ dàng thêm model mới vào ensemble
- **Tính linh hoạt**: Có thể điều chỉnh ngưỡng consensus theo yêu cầu

4.5.3 Các chỉ số đánh giá chính

Bảng 8: Chỉ số đánh giá hệ thống annotation

Chỉ số	Công thức	Mục tiêu	Ý nghĩa
Consensus Rate	$\frac{N_{\text{consensus}}}{N_{\text{total}}}$	$> 80\%$	Tỷ lệ samples tự động hóa
Human Effort Saved	$1 - \frac{N_{\text{human}}}{N_{\text{total}}}$	$> 85\%$	Hiệu quả giảm công sức
Annotation Accuracy	$\frac{N_{\text{correct}}}{N_{\text{validated}}}$	$> 99\%$	Chất lượng annotation
Cost per Sample	$\frac{\text{Total Cost}}{N_{\text{total}}}$	$< \$0.05$	Hiệu quả kinh tế
Time per Sample	$\frac{\text{Total Time}}{N_{\text{total}}}$	< 30s	Tốc độ xử lý

5 Dataset Strategy và Training Timeline

5.1 Phân phối Dataset theo Giai đoạn Training

Chiến lược dataset được thiết kế đặc biệt cho pipeline training 4 giai đoạn của Proposal Model, với sự gia tăng độ phức tạp và chuyên biệt hóa qua từng phase.

5.1.1 Tổng quan Phân phối Dataset

Bảng 9: Phân phối dataset theo các giai đoạn training

Giai đoạn	English	Vietnamese	Tổng	Đặc điểm chính
Phase 1: Encoder Pretrain	4M	3M	7M	General document understanding
Phase 2: Layout Decoder	400K	100K	500K	Layout annotation quality
Phase 3: Content Decoder	600K	200K	800K	Task-specific fine-tuning
Phase 4: Joint Fine-tune	200K	80K	280K	High-quality balanced
Total	5.2M	3.38M	8.58M	

5.2 Phase 1: Encoder Pretraining Dataset

5.2.1 Mục tiêu và Yêu cầu

- **Mục tiêu**: Học biểu diễn visual đa độ phân giải hiệu quả
- **Phương pháp**: Masked Image Modeling (MIM) với multi-scale reconstruction
- **Yêu cầu**: Dữ liệu đa dạng, chất lượng hình ảnh cao, cân bằng domain

5.2.2 Thành phần Dataset

Bảng 10: Thành phần dataset Phase 1

Loại dữ liệu	English	Vietnamese	Đặc điểm kỹ thuật
PDF Association	1.5M	-	Academic, business, legal
arXiv Papers	1.2M	-	STEM fields, LaTeXsource available
Gov Documents	-	1.2M	Legal, administrative, forms
Vietnamese News	-	800K	Online newspapers, multi-domain
Scanned Books	800K	600K	Historical, library collections
Synthetic Data	500K	400K	Augmented variations
Web Crawled	500K	400K	Diverse layouts and styles

5.2.3 Data Preparation Pipeline

1. **Data Cleaning**:
   - Loại bỏ corrupted files, low-resolution images
   - Normalize DPI: 200-300 DPI cho tất cả samples
   - Deskew và denoise cho scanned documents
2. **Preprocessing**:
   - Extract text layer từ PDF (nếu có)
   - Generate synthetic variations: rotation, noise, blur
   - Chunk documents thành individual pages
3. **Augmentation Strategy**:
   - Geometric: Rotation (±5°), scaling (0.9-1.1)
   - Photometric: Contrast, brightness, color jitter
   - Noise: Gaussian, speckle, salt-and-pepper
   - Degradation: Blur, compression artifacts

5.2.4 Công cụ đề xuất

- **PDF Processing**: PDFExtract-Kit, PyMuPDF, Camelot
- **Image Processing**: OpenCV, Pillow, Albumentations
- **Data Management**: DVC (Data Version Control), Apache Parquet
- **Distributed Processing**: Apache Spark, Dask

5.3 Phase 2: Layout Decoder Training Dataset

5.3.1 Mục tiêu và Yêu cầu

- **Mục tiêu**: Học accurate layout analysis với reading order
- **Annotation chất lượng**: Bounding box, class, rotation, reading order
- **Độ phức tạp**: Đa dạng layout types và document structures

5.3.2 Thành phần Dataset

Bảng 11: Thành phần dataset Phase 2

Layout Type	English	Vietnamese	Độ khó
Single Column	120K	30K	Dễ (textbook, novel)
Double Column	100K	25K	Trung bình (academic papers)
Mixed Layout	80K	20K	Khó (magazines, reports)
Forms & Tables	50K	15K	Rất khó (complex forms)
Scientific Docs	30K	5K	Đặc biệt (math, formulas)
Scanned Historical	20K	5K	Rất khó (degraded quality)

5.3.3 Annotation Specifications

Bảng 12: Chi tiết annotation cho layout analysis

Element Type	Classes	Annotation Details
Text Elements	8 classes	Paragraph, heading, caption, footnote, etc.
Graphical Elements	5 classes	Figure, chart, diagram, photo, signature
Structural Elements	6 classes	Table, formula, code block, list, quote
Meta Elements	4 classes	Page number, header, footer, watermark
Attributes	4 types	BBox, rotation, reading order, confidence

5.3.4 Quality Control Measures

- **Inter-annotator Agreement**: > 0.9 Cohen's Kappa
- **Validation Split**: 20% cho validation, 10% cho test
- **Consistency Checks**: Automated validation rules
- **Periodic Audits**: Monthly quality audits với expert review

5.4 Phase 3: Content Decoder Training Dataset

5.4.1 Phân chia theo Task

Bảng 13: Phân bố dataset theo content type

Task	English	Vietnamese	Total	Đặc điểm
Text Recognition	300K	100K	400K	Dense text, mixed fonts
Table Recognition	150K	50K	200K	Simple to complex tables
Formula Recognition	100K	40K	140K	Inline và display formulas
Mixed Content	50K	10K	60K	Combined elements

5.4.2 Text Recognition Dataset

- **English Subset**:
  - Academic papers: 100K samples
  - Business documents: 80K samples
  - Legal texts: 60K samples
  - News articles: 40K samples
  - Handwritten samples: 20K samples
- **Vietnamese Subset**:
  - Gov documents with diacritics: 40K samples
  - Literature with poetry: 30K samples
  - Technical manuals: 20K samples
  - Handwritten Vietnamese: 10K samples

5.4.3 Table Recognition Dataset

Bảng 14: Đặc điểm table recognition dataset

Table Type	Samples	Complexity	Annotation Format
Simple Grid	80K	Dễ (regular cells)	HTML basic
Merged Cells	60K	Trung bình	HTML with rowspan/colspan
Nested Tables	30K	Khó	Hierarchical OTSL
Borderless	20K	Rất khó	Inferred structure
Rotated Tables	10K	Đặc biệt	With rotation metadata

5.4.4 Formula Recognition Dataset

- **Source Types**:
  - LaTeX-compiled: 60K samples (clean ground truth)
  - Scanned textbooks: 40K samples (degraded quality)
  - Handwritten equations: 20K samples (varied styles)
  - Mixed text-formula: 20K samples (contextual)
- **Complexity Levels**:
  - Simple: 40K (basic arithmetic)
  - Intermediate: 60K (fractions, matrices)
  - Advanced: 40K (integrals, summations)

5.5 Phase 4: Joint Fine-tuning Dataset

5.5.1 High-Quality Curation

Bảng 15: Chất lượng dataset Phase 4

Quality Metric	Target	Measurement Method
Annotation Accuracy	> 99.5%	Expert review on random samples
Layout Consistency	> 0.95 PageIoU	Automated validation
Content Fidelity	CER < 0.01	Comparison with source
Domain Coverage	10+ domains	Manual categorization
Difficulty Balance	30-40-30 (E-M-H)	Complexity scoring

5.5.2 Domain Distribution

- **Academic Research**: 25% (papers, theses, reports)
- **Business & Finance**: 20% (reports, statements, contracts)
- **Legal & Government**: 15% (laws, regulations, forms)
- **Healthcare & Medical**: 15% (records, research, journals)
- **Education**: 10% (textbooks, exams, materials)
- **News & Media**: 10% (articles, magazines, newsletters)
- **Technical Manuals**: 5% (specs, guides, documentation)

5.5.3 Hard Case Mining

- **Selection Criteria**:
  - Model prediction confidence < 0.7
  - Inter-model disagreement > 30%
  - Complex layout patterns (multi-column, wrapping)
  - Degraded image quality (blur, noise, low contrast)
- **Enhancement Strategies**:
  - Active learning feedback loop
  - Synthetic difficulty augmentation
  - Adversarial example generation